

① Sorpresa como función de probabilidad.

Para un resultado X al que un modelo asigna una probabilidad P , se define su sorpresa como

$$S(p) : p \in (0,1]$$

② Axiomas:

- **Monotonía:** Si un evento es menos probable, sorprende más.

$$p_1 < p_2 \rightarrow S(p_1) > S(p_2)$$

- **Cero sorpresa para lo seguro:**

$$p = 1 \leftrightarrow S(p) = 0$$

- **Aditividad para eventos independientes:**

$$S(p_1 p_2) = S(p_1) + S(p_2)$$

- **Regularidad suave:**

Pequeños cambios en p no deben producir grandes cambios de sorpresa.

$$S'(p) = -\log p$$

③ Entropía de Shannon:

Medida de "costo"/incertidumbre

$$H(p) = \mathbb{E}[S(p)] = -\sum_i p_i \log p_i$$

El costo promedio óptimo de describir muestras $x \sim P$ usando la expresión de $P(x)$ es:

$$\mathbb{E}_{x \sim P}[-\log P(x)]$$

Ahora, si los datos vienen de P , pero se modela respecto a Q

$$\mathbb{E}_{x \sim P}[-\log q(x)]$$

Entonces, la diferencia de describir a x con Q cuando $x \sim P$ es

$$\mathbb{E}_{x \sim P}[-\log q(x)] - \mathbb{E}_{x \sim P}[-\log p(x)]$$

$$= \mathbb{E}_{x \sim P}[-\log q(x)] + \mathbb{E}_{x \sim P}[\log p(x)]$$

$$= \mathbb{E}_{x \sim P}[-\log q(x) + \log p(x)]$$

$$= \mathbb{E}_{x \sim P} \left[\log \left(\frac{p(x)}{q(x)} \right) \right] \triangleq D_{KL}(P \| Q)$$