

Sea  $x \in \mathbb{R}^d$  un vector aleatorio con  $\mu = \mathbb{E}[x]$ , se define el centrado:

$$\tilde{x} := x - \mu \Rightarrow \mathbb{E}[\tilde{x}] = 0$$

La covarianza de  $x$  (equivalente a la de  $\tilde{x}$ ) se define como

$$\Sigma := \text{Cov}[x] = \mathbb{E}[(x - \mu)(x - \mu)^T] = \mathbb{E}[\tilde{x}\tilde{x}^T]$$

**Demstrar:** Sea  $w \in \mathbb{R}^d$  un vector fijo (no aleatorio), entonces

$$\text{Var}[w^T \tilde{x}] = w^T \Sigma w$$

Considere al escalar  $z := w^T \tilde{x}$ , entonces

$$\mathbb{E}[z] = \mathbb{E}[w^T \tilde{x}] = w^T \mathbb{E}[\tilde{x}] = w^T \cdot 0 = 0$$

Luego, la varianza:

$$\text{Var}[z] = \mathbb{E}[z^2] - (\mathbb{E}[z])^2 = \mathbb{E}[z^2]$$

$$\mathbb{E}[z^2] = \mathbb{E}[(w^T \tilde{x})^2] = \mathbb{E}[(w^T \tilde{x})(w^T \tilde{x})]$$

Como  $w^T \tilde{x} \in \mathbb{R}$  entonces  $w^T \tilde{x} = \tilde{x}^T w$ , entonces

$$\mathbb{E}[z^2] = \text{Var}[z] = \mathbb{E}[(w^T \tilde{x})(\tilde{x}^T w)]$$

$$a^T b b^T a = a^T (b b^T) a$$

$$\mathbb{E}[w^T (\tilde{x} \tilde{x}^T) w] = w^T \mathbb{E}[\tilde{x} \tilde{x}^T] w = w^T \Sigma w \quad \square$$

$$\bullet \text{tr}(W^T X^T X W) = \sum_{j=1}^k w_j^T X^T X w_j = \sum_{j=1}^k \text{Var}[w_j^T \tilde{x}]$$

Minimizar error de reconstrucción = maximizar varianza de las proyecciones.

Se tienen datos  $x_1, x_2, \dots, x_n \in \mathbb{R}^d$ . Primero centramos:

$$\tilde{x}_i = x_i - \bar{x}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{y apilamos en una}$$

matriz:

$$X = \begin{pmatrix} \tilde{x}_1^T \\ \tilde{x}_2^T \\ \vdots \\ \tilde{x}_n^T \end{pmatrix} \Rightarrow X \in \mathbb{R}^{n \times d}$$

Buscamos un subespacio de dimensión  $k$  con una base ortonormal  $W \in \mathbb{R}^{d \times k}$  tal que

$$W^T W = I_k : W = [w_1, w_2, \dots, w_k]$$

La proyección ortogonal de  $\tilde{x}_i$  sobre ese subespacio es:

$$\hat{x}_i = W W^T \tilde{x}_i$$

La idea: Aproximar cada  $\tilde{x}_i$  por medio de  $\hat{x}_i$  y minimizar el error cuadrático total:

$$\min_{W^T W = I_k} \sum_{i=1}^n \|\tilde{x}_i - W W^T \tilde{x}_i\|^2$$

En forma matricial:

$\|\cdot\|_F$ : Norma de Frobenius

$$\min_{W^T W = I_k} \|X - X W W^T\|_F^2$$

Expandiendo mediante la identidad  $\|A\|_F^2 = \text{tr}(A^T A)$  se llega a:

$$\|X - X W W^T\|_F^2 = \underbrace{\text{tr}(X^T X)}_{\text{No depende de } W} - \text{tr}(W^T X^T X W)$$

$$\min_{W^T W = I_k} \|X - X W W^T\|_F^2 = \max_{W^T W = I_k} \text{tr}(W^T X^T X W)$$

$$\max_{W \in \mathbb{R}^{d \times k}} \text{tr}(W^T \Sigma W) \text{ sujeto a } W^T W = I_k$$

El Lagrangiano:

$$\mathcal{L}(W, \Lambda) = \text{tr}(W^T \Sigma W) - \text{tr}(\Lambda (W^T W - I))$$

con  $\Lambda \in \mathbb{R}^{k \times k}$  matriz de multiplicadores.

Por medio de diferenciales, se tiene:

$$d\mathcal{L} = 2 \text{tr}((\Sigma W - W \Lambda)^T dW)$$

Iguando a 0:

$$2 \text{tr}((\Sigma W - W \Lambda)^T dW) = 0 \quad \forall dW$$

$$(\Sigma W - W \Lambda)^T dW = 0 \quad \forall dW$$

$$(\Sigma W - W \Lambda)^T = 0$$

$$\Sigma W - W \Lambda = 0$$

$$\Sigma W = W \Lambda$$

Que tiene como solución

$$\Lambda = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_k \end{pmatrix} \rightarrow \text{Matriz diagonal de autovalores tal que } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$$

$$W^* = [q_1, q_2, \dots, q_k]$$

$\hookrightarrow$  Matriz de autovectores de  $\Sigma = X^T X$